



CENTRO UNIVERSITÁRIO - CATÓLICA DE SANTA CATARINA
ENGENHARIA DE SOFTWARE
ANÁLISE PREDITIVA

ANA CAROLINA FANHANI STRALIOTI
GUSTAVO DO PRADO
JAIRSON STEINERT

AVALIAÇÃO N1

JARAGUÁ DO SUL

2026

SUMÁRIO

1. ETAPA 1 - AUDITORIA DOS DADOS (DIAGNÓSTICO).....	3
2. ETAPA 2 - TRATAMENTO E PRERAÇÃO.....	3
3. ETAPA 3 - ANÁLISE EXPLORATÓRIA (EDA).....	4
4. ETAPA 4 - DATA STORYTELLING.....	4

1. ETAPA 1 - AUDITORIA DOS DADOS (DIAGNÓSTICO)

Para a etapa de auditoria de dados, realizou-se uma auditoria no dataset extraído do Yahoo Finance (entre janeiro de 2021 a março de 2026), identificou-se valores ausentes na etapa de criação de médias móveis, o que gerou valores nulos (NaN) nas primeiras linhas do dataset (período de carência para o cálculo da janela de dias). Para o tratamento destes dados, optou-se pela remoção dessas linhas usando a função `dropna()`, resultando em um dataset limpo de 1874 linhas.

No que se trata de outliers e volatilidade, reconhece-se que o mercado de criptomoedas, especialmente o de Bitcoin, é inerentemente complexo e apresenta extrema volatilidade. Picos de preço e volume são comuns e representam o comportamento real do ativo. Para o tratamento, neste caso, optou-se por não remover os outliers para não perder a não-linearidade do mercado, mas aplicamos normalização.

Quanto à inconsistências temporais, definiu-se a frequência da série como diária, sendo o tratamento realizado por meio do índice temporal padronizado na coluna `Date` durante a exportação para o banco SQLite.

2. ETAPA 2 - TRATAMENTO E PRERAÇÃO

A pipeline de dados foi construída para alimentar o modelo de aprendizado de máquina focado no fechamento do dia seguinte, de forma que os dados foram consolidados no banco de dados local `crypto_data.db` e manipulados via Pandas em memória. Devido à grande amplitude dos valores nominais do Bitcoin, aplicamos o `MinMaxScaler` do `scikit-learn` nas variáveis de entrada (OHLCV e médias móveis), escalonando os dados para um intervalo entre 0 e 1.

Foram criadas variáveis derivadas: a `SMA_7` (Simple Moving Average 7-day), que é calculada para capturar tendências de curto prazo do preço de fechamento e a `SMA_30` (Simple Moving Average 30-day), que é calculada para identificar tendências de médio e longo prazo. Além da criação da variável alvo: a coluna `Target` foi gerada deslocando o preço de fechamento em uma unidade (`shift(-1)`), representando o valor exato a ser previsto.

3. ETAPA 3 - ANÁLISE EXPLORATÓRIA (EDA)

A exploração do dataset estruturado buscou validar as premissas de negócio e entender a dinâmica temporal, desta maneira, levantou-se a hipótese de que a combinação das variáveis `SMA_7` e `SMA_30` possui um peso preditivo maior para determinar o `Target` do que o preço de abertura (`Open`) de forma isolada. O cruzamento dessas médias costuma preceder fortes movimentos direcionais.


Também identificou-se que o volume de negociação atua como um termômetro de mercado, a hipótese a ser validada no modelo é se dias com picos anômalos de volume geram maior margem de erro nas previsões (MAE diário maior) devido à alta volatilidade irracional.

Por fim, o objetivo técnico da análise é garantir que as variáveis OHLCV e as médias móveis contêm informação suficiente para que o futuro modelo atinja um score superior a 0.60 e uma acurácia de direção maior que 50%.

4. ETAPA 4 - DATA STORYTELLING

O Bitcoin carece de mecanismos tradicionais de precificação, sendo altamente sensível a eventos globais e geopolíticos. Hoje, investidores perdem oportunidades e enfrentam dificuldades no planejamento estratégico devido à incapacidade de antecipar a direção do ativo.

Para enfrentar essa dificuldade, a atual análise de dados (de janeiro de 2021 a março de 2026) isolou o sinal do ruído. Observou-se que o preço isolado não conta toda a história; é a relação temporal — representada pelas médias móveis de curto e médio prazo (SMA_7 e SMA_30) combinadas com o volume de negociação — que dita a força da tendência. O volume, por sua vez, pode ser um "falso amigo", onde picos extremos indicam volatilidade que pode confundir algoritmos lineares.



Como podemos ver no gráfico da Análise de Tendência acima, os dados confirmam a extrema volatilidade e a não-linearidade histórica do Bitcoin. A linha de fechamento diário (Close) apresenta flutuações bruscas que provam que o uso isolado do preço atual é insuficiente para prever o movimento do dia seguinte com segurança.

A partir desta visualização, destacamos três descobertas cruciais para a modelagem: a primeira de que a Média Móvel de 7 dias (SMA_7) atua como um termômetro de curto prazo,

acompanhando de perto os "solavancos" do preço e o sentimento imediato do mercado. Por outro lado, a Média Móvel de 30 dias (SMA_30) funciona como uma âncora, suavizando o ruído diário e revelando a verdadeira direção de médio e longo prazo do ativo.

Segundo, o gráfico demonstra visualmente que os momentos em que a linha de curto prazo (SMA_7) cruza a linha de longo prazo (SMA_30) precedem grandes ralis de alta ou fortes correções de baixa. Isso valida a premissa de que a interação entre essas médias possui um forte peso preditivo (*feature importance*) para determinar o preço Target.

Por fim, a terceira descoberta é de que nos picos do mercado, nota-se que a linha do preço real (Close) descola-se drasticamente da SMA_30. Esses momentos evidenciam a complexidade do mercado de criptomoedas e justificam a probabilidade de um maior erro preditivo (RMSE elevado) em dias de comportamento irracional. Em suma, a extração dessas variáveis derivadas (SMA) provou-se essencial na etapa de ETL. Elas fornecem ao algoritmo de *Machine Learning* o contexto temporal necessário para buscar a meta de atingir uma acurácia direcional superior a 50%.

O produto final deste refinamento de dados é uma base normalizada. O modelo preditivo que consumirá esses dados visará reduzir os riscos acentuados, fornecendo insights baseados em dados para antecipar o mercado. O sucesso será medido pela capacidade matemática do modelo de acertar a direção do fechamento do dia seguinte na maioria das vezes, penalizando grandes desvios com a métrica RMSE.